Отчет команды 1 БСМО-11-22:
Александрова Мария Константиновна
Кучеренко Кирилл Иванович
Кузьмин Артём Владимирович
Ляхов Тимофей Алексеевич
Клейменов Андрей Артемович

Задание 3: https://github.com/Sailats/3prac

Определение типа текста на изображении. Форма приложения:

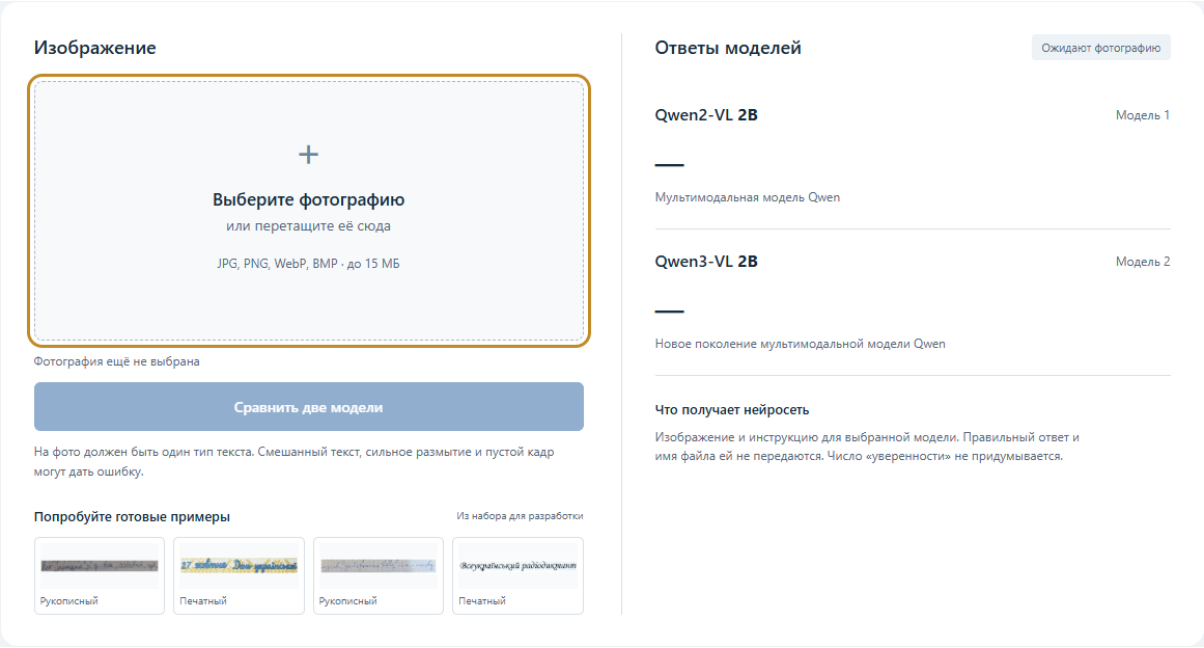


Рисунок 1 - Форма загрузки изображения и карточки двух моделей

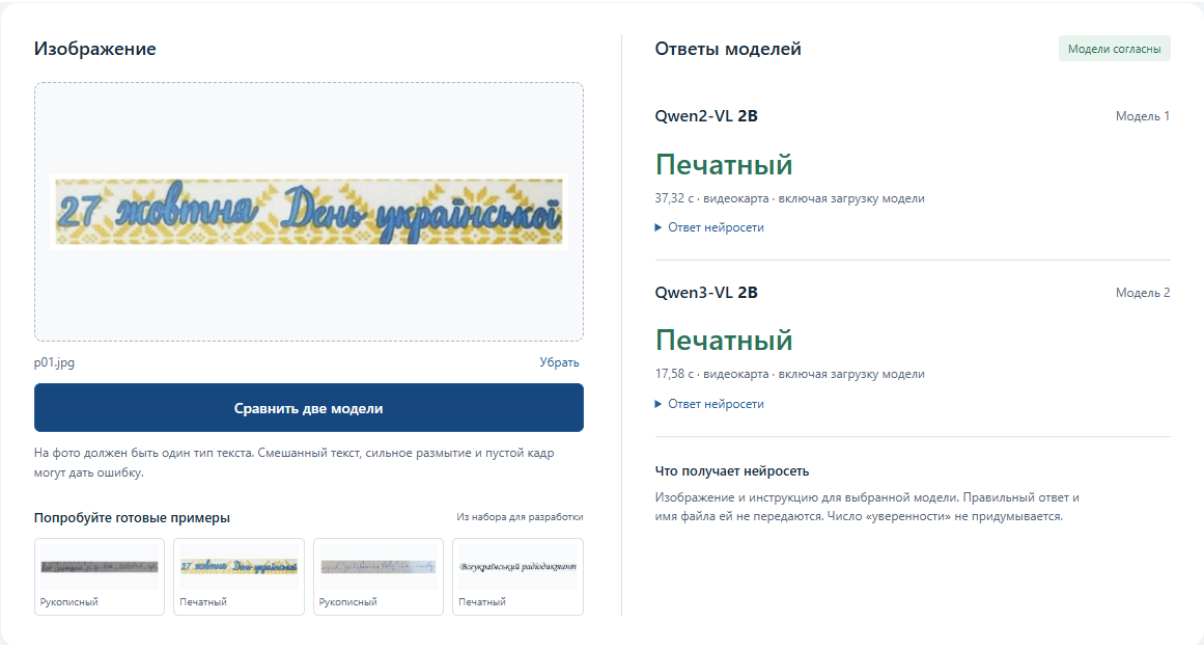


Рисунок 2 - Определение печатного текста обеими моделями

Работа приложения с рукописным текстом и запуск сравнительного эксперимента:

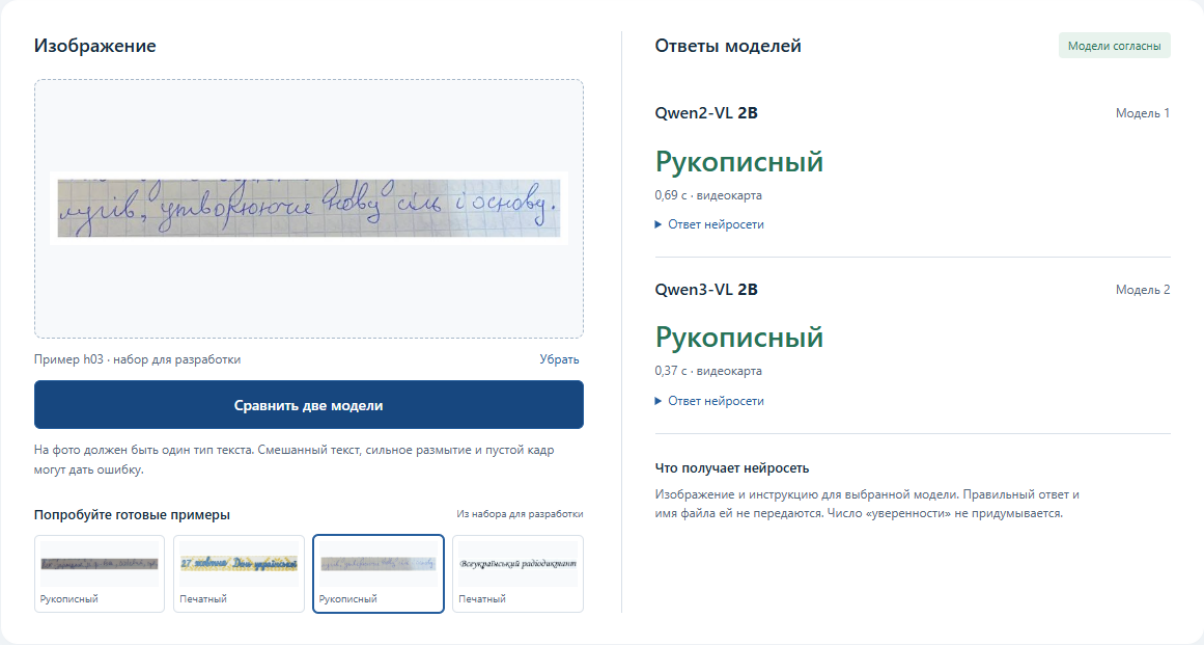


Рисунок 3 - Определение рукописного текста на примере h03

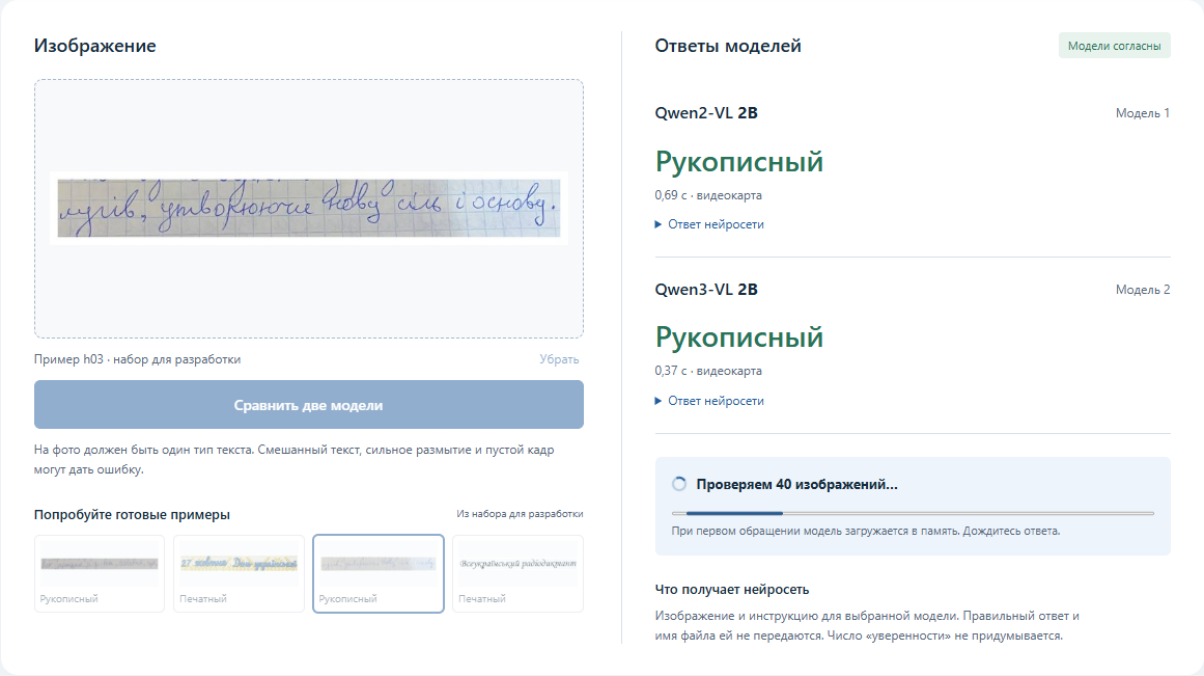
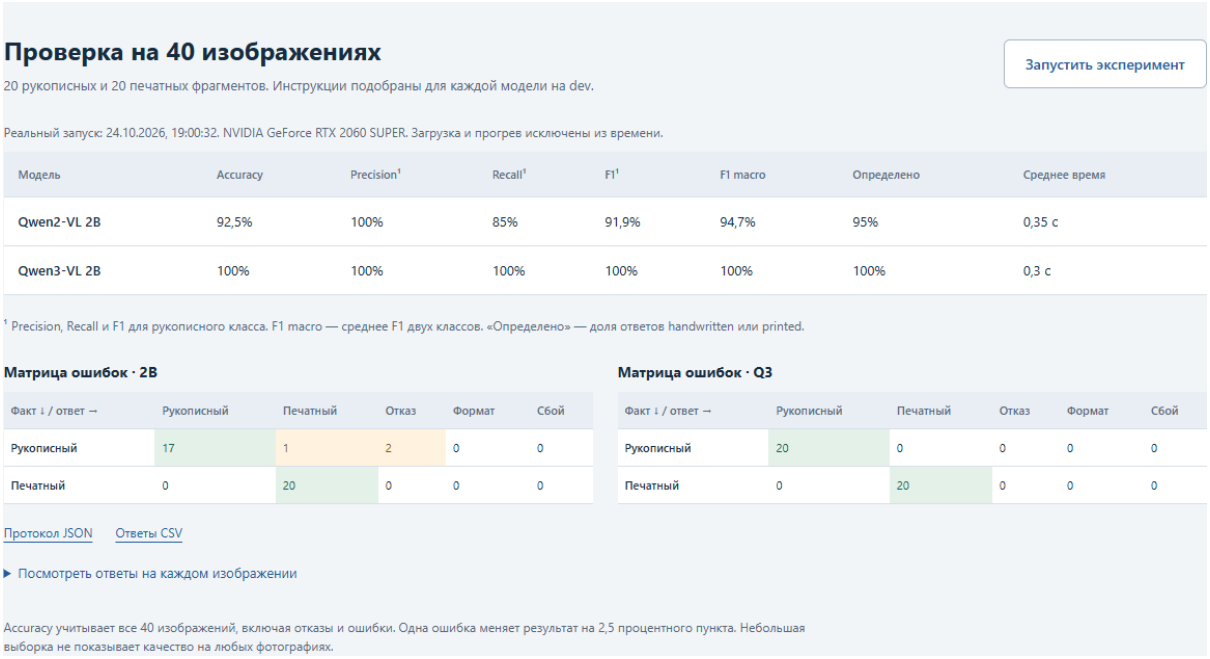


Рисунок 4 - Выполнение проверки на 40 изображениях

Во время вычислений элементы управления блокируются, а браузер асинхронно ожидает прямой ответ сервера. Две модели вызываются последовательно. При первом обращении дополнительное время занимает загрузка весов в память.

Результаты эксперимента и анализ ошибочного ответа:



Проверка на 40 изображениях

Запустить эксперимент

20 рукописных и 20 печатных фрагментов. Инструкции подобраны для каждой модели на dev.

Реальный запуск: 24.10.2026, 19:00:32. NVIDIA GeForce RTX 2060 SUPER. Загрузка и прогрев исключены из времени.

Модель	Accuracy	Precision[1]	Recall[1]	F1[1]	F1 macro	Определено	Среднее время
Qwen2-VL 2B	92,5%	100%	85%	91,9%	94,7%	95%	0,35 с
Qwen3-VL 2B	100%	100%	100%	100%	100%	100%	0,3 с

[1] Precision, Recall и F1 для рукописного класса. F1 macro — среднее F1 двух классов. «Определено» — доля ответов handwritten или printed.

Матрица ошибок · 2B

Факт ↓ / ответ →	Рукописный	Печатный	Отказ	Формат	Сбой
Рукописный	17	1	2	0	0
Печатный	0	20	0	0	0

Матрица ошибок · Q3

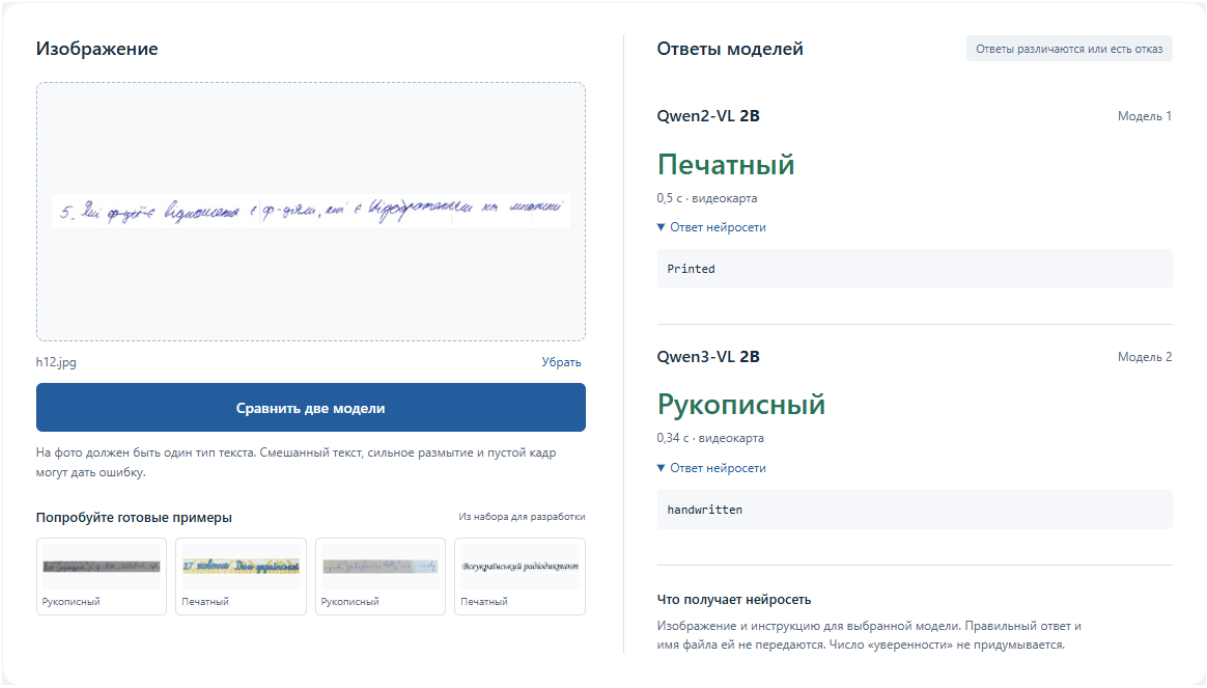
Факт ↓ / ответ →	Рукописный	Печатный	Отказ	Формат	Сбой
Рукописный	20	0	0	0	0
Печатный	0	20	0	0	0

Протокол JSON Ответы CSV

▶ Посмотреть ответы на каждом изображении

Accuracy учитывает все 40 изображений, включая отказы и ошибки. Одна ошибка меняет результат на 2,5 процентного пункта. Небольшая выборка не показывает качество на любых фотографиях.

Рисунок 5 - Итоговые метрики и матрицы ошибок двух моделей



Изображение

h12.jpg Убрать

Сравнить две модели

На фото должен быть один тип текста. Смешанный текст, сильное размытие и пустой кадр могут дать ошибку.

Попробуйте готовые примеры Из набора для разработки

Рукописный Печатный Рукописный Печатный

Ответы моделей Ответы различаются или есть отказ

Qwen2-VL 2B Модель 1

Печатный

0,5 с · видеокарта

▼ Ответ нейросети

```
Printed
```

Qwen3-VL 2B Модель 2

Рукописный

0,34 с · видеокарта

▼ Ответ нейросети

```
handwritten
```

Что получает нейросеть

Изображение и инструкцию для выбранной модели. Правильный ответ и имя файла ей не передаются. Число «уверенности» не придумывается.

Рисунок 6 - Расхождение на рукописном h12: ошибка Qwen2-VL

На h12 модель Qwen2-VL отвечает Printed, а Qwen3-VL - handwritten. Истинный класс фрагмента - рукописный. Сырые ответы раскрыты на рисунке 6 и сохраняются в протоколе; программа не подменяет неудачный ответ правильной меткой.

Сравнение качества мультимодальных моделей

Цель работы - реализовать приложение, определяющее по изображению, является ли текст рукописным или печатным, и сравнить две предобученные модели по качеству и времени. Использованы Qwen2-VL 2B и Qwen3-VL 2B. Модели выполняются локально; подписка, токен и платные запросы к сервису вывода не требуются. Дополнительное обучение не проводилось.

Для проверки подготовлены 50 реальных фрагментов фотографий и сканов из открытого набора UkrainianCatholicUniversity/rukopys (CC BY 4.0): 25 рукописных и 25 печатных. Из них 10 dev-примеров использовались для проверки инструкций, а 40 test-примеров, по 20 каждого класса, - для сравнительного эксперимента. Каждый фрагмент взят из отдельного исходного документа; авторы почерка в наборе не идентифицированы.

Вход переводится в RGB, максимальная сторона ограничивается 1024 пикселями, после чего применяется штатный процессор модели. Генерация выполняется без случайного сэмплирования, максимум 12 новых токенов. Для размещения обеих моделей в памяти GPU линейные слои декодера подготовлены в NF4; visual и lm_head сохранены в FP16. Правильная метка и имя файла в модель не передаются.

Таблица 1 - Качество и время обработки на 40 изображениях

Модель	**Accuracy %**	**Precision[1] %**	**Recall[1] %**	**F1[1] %**	**F1 macro %**	**Coverage %**	**Среднее время, с**
Qwen2-VL 2B	92,5	100,0	85,0	91,9	94,7	95,0	0,35
Qwen3-VL 2B	100,0	100,0	100,0	100,0	100,0	100,0	0,30

[1] Precision, Recall и F1 приведены для класса «Рукописный». Coverage - доля ответов одного из двух целевых классов. Время измерено после прогрева на RTX 2060 SUPER; загрузка весов и открытие исходных байтов изображения исключены, подготовка тензоров процессором входит в замер.

Accuracy = число правильных ответов / все 40 примеров. Отказы unknown, неверный формат invalid и технические ошибки error не исключаются из знаменателя. В выполненном прогоне у Qwen2-VL было 37 правильных ответов, один ошибочный класс и два отказа; у Qwen3-VL - 40 правильных ответов. Неверных форматов и технических сбоев не было.

Основной код упрощён до трёх модулей: app.py - маршруты Flask и интерфейс, predict.py - подготовка изображения и вызовы моделей, evaluate.py - эксперимент и метрики. Самописные HTTP-обработчики, менеджер фоновых задач и опрос состояния удалены; установка и подготовка весов вынесены в support/. Сервер сокращён со 193 до 108 строк, параметры моделей сохранены.

Вывод по практической работе

В ходе практической работы реализовано работоспособное локальное приложение для классификации типа текста на изображении. Пользователь может загрузить собственную фотографию или выбрать готовый пример, получить ответы двух мультимодальных моделей, просмотреть исходные строки генерации и выполнить повторный сравнительный эксперимент. Задача ограничена определением класса «рукописный/печатный» и не включает полноценное OCR-переписывание содержания документа.

Для эксперимента использованы открытые предобученные модели и размеченные реальные фрагменты из rukopys. Собственная нейросеть с нуля не разрабатывалась и дообучение на этих 50 изображениях не выполнялось. Разработанная часть работы включает подготовку данных и изображений, интеграцию двух моделей, веб-интерфейс, процедуру сравнения, расчёт метрик и сохранение проверяемых JSON/CSV-протоколов.

Повторная проверка после упрощения кода сохранила качество предыдущей версии: Qwen2-VL 2B правильно классифицировала 37 из 40 изображений (Accuracy 92,5%), Qwen3-VL 2B - 40 из 40 (100%). Среднее время после прогрева составило соответственно 0,35 и 0,30 секунды на указанной видеокарте. Ошибки Qwen2 относились к рукописным примерам: один фрагмент был принят за печатный, на двух получен unknown. Отказы остались в общей оценке, поэтому неудачные ответы не были отброшены для повышения точности.

Результаты относятся к конкретной небольшой выборке и настройкам. Эти же 40 изображений использовались ранее, поэтому новый прогон является повторным учебным сравнением, а не независимым тестом. Формулировки инструкций выбраны отдельно на dev для каждой модели; сравниваются две настроенные программные связки. Документы различны, но независимость авторов почерка не установлена. Пустые, смешанные и произвольные полноформатные страницы отдельно не оценивались. Для более надёжного вывода необходима новая, более крупная и разнообразная выборка.

Структура приложения стала проще для изучения и защиты: три основных файла отделены от служебной установки, браузер получает прямой JSON-ответ, вычисления на сервере выполняются последовательно. Проверены 22 автоматических теста, реальные ответы через интерфейс и работа на узком экране. Скриншоты в отчёте получены из работающей упрощённой версии, включая пример реального расхождения моделей.

Таким образом, цель работы достигнута: создано приложение, позволяющее бесплатно выполнять локальную классификацию и сравнивать два подхода по качеству и задержке. В исходном обсуждении задания указан Hugging Face Inference Providers; здесь этот способ вызова заменён локальным выполнением официальных весов. Если требуется строго облачный провайдер, данное отличие необходимо учитывать.

Фактический протокол: test_20261024_160032.json. Дата: 24.10.2026. Параметры, исходные ответы, ревизии моделей и хеши данных сохранены в results/.